# Deep Learning — UAS Session 16: Group Project Proposal

**Group Project Proposal Template — Track A: Vision Classification with Transfer Learning**

## 1. Identification

| Field | Content |
|---|---|
| **Group number** | Kelompok 5 |
| **Members and NIM** | Tita Noviana — `24120500011`<br>Titanio Yudista — `24120500031`<br>Suci Fransisca Sisilia R. — `24130500008`<br>Fajar Dwiharjo — `24130500010` |
| **Track** | A (Vision classification with transfer learning) |
| **Proposed title** | Evaluasi *From-Scratch CNN* dan *Fine-Tuned EfficientNet-B0* untuk *Fine-Grained Classification* Motif Batik Semarang pada Kondisi Deformasi Kain |

## 2. Problem Statement

- **Supported decision/prediction:** Mendukung sistem kurasi digital museum tekstil, pengarsipan warisan budaya, dan verifikasi katalog *e-commerce* otomatis untuk 10 kelas motif batik Semarang.
- **End users and failure cost:** Kurator museum, peneliti tekstil, dan pengelola *platform* kriya. Kesalahan klasifikasi menyebabkan pencemaran basis data arsip budaya (*archive contamination*), kesalahan pelabelan katalog komersial, dan degradasi reputasi kuratorial.
- **Appropriateness of deep learning:** Citra batik dunia nyata mengalami deformasi *non-rigid*, lipatan kain (*fabric folds*), variasi skala dan pencahayaan, serta kemiripan *inter-class* ornamen latar (*isen-isen*) yang sulit digeneralisasi oleh ekstraksi fitur manual (SIFT/HOG).

## 3. Data

| Field | Content |
|---|---|
| **Dataset name** | Semarang Batik Dataset |
| **Source URL** | `https://www.kaggle.com/datasets/edywinarno/semarang-batik-dataset` (Winarno et al., ACM ICACS 2017) |
| **Licence or terms of use** | Lisensi penggunaan publik dan akademik sesuai ketentuan Kaggle (*Academic Research Use*) |
| **Size and number of classes** | $\sim$ 3.000 citra RGB ($224 \times 224$) terbagi secara berimbang ke dalam 10 kelas motif Semarang |
| **Class balance** | Relatif seimbang ($\sim$ 300 citra/kelas); diverifikasi melalui *exploratory data analysis* (EDA) sebelum pemisahan |
| **Known missing or corrupted data** | Pengecekan otomatis menggunakan skrip Python (PIL/OpenCV) untuk memfilter *corrupted image headers* atau *invalid color channels* sebelum *splitting* |
| **Split procedure (train / validation / test)** | *Stratified split* 70% *Train* / 15% *Validation* / 15% *Test* dengan *fixed random seed* (`seed=42`) |
| **Leakage risks and how to check them** | Risiko *data leakage* akibat *exact/near-duplicate images* yang bocor antar-*split*, serta kebocoran dari *augmentation*. Dicek menggunakan *Perceptual Hashing* (`pHash`) sebelum *splitting*; *data augmentation* hanya *on-the-fly* pada *training set*. |

## 4. Baseline and Metric

| Field | Content |
|---|---|
| **Baseline method** | Arsitektur *Custom 4-Block CNN* (`Conv2D + BatchNorm + ReLU + MaxPool + AdaptiveAvgPool + Linear head`) yang dilatih *from-scratch* |
| **Why this baseline is a fair comparison** | *Data split*, resolusi input ($224 \times 224$), *optimizer* (`AdamW`), dan *epoch budget* identik untuk mengisolasi kontribusi *pretrained feature representations*. |
| **Primary metric** | *Macro F1-Score*, objektif terhadap potensi ketimpangan tipis antar 10 kelas |
| **Secondary metric** | *Top-1 Accuracy*, *Top-3 Accuracy*, serta *training time/cost per run* |
| **Success threshold** | Model *transfer learning* mencapai $\geq 85\%$ *Macro F1-Score* dan mengungguli *baseline CNN from-scratch* minimal $+10\%$ *Macro F1* pada *test set* |
| **Cost of false positive vs false negative** | *False Positive* mencemari arsip dengan pola motif yang salah (*archive contamination*); *False Negative* membuat motif asli gagal dikenali sehingga perlu verifikasi manual ulang. |

## 5. Planned Comparison and Ablation

1. **Model families to compare:** *Custom 4-Layer CNN (From-Scratch)* vs *Pretrained EfficientNet-B0 / ResNet-50 (Transfer Learning)*. *Hierarchical features* dari ImageNet diharapkan menangkap tekstur *fine-grained* batik lebih baik daripada model tanpa induksi bobot apriori.
2. **Ablation:** Mengisolasi *Geometric & Photometric Data Augmentation (On vs Off)*—*random rotation*, *affine transform* (simulasi lipatan), dan *color jitter*—sementara arsitektur, *learning rate*, *batch size*, dan *random seed* konstan.
3. **The one model trained or fine-tuned:** *Custom PyTorch training loop* untuk CNN *from-scratch* dan *two-stage fine-tuning* EfficientNet-B0: tahap 1 *linear probing* dengan *frozen backbone*; tahap 2 *unfreezing top blocks* dengan `CosineAnnealingLR` dan `AdamW`.

## 6. Compute Plan

| Field | Content |
|---|---|
| **Hardware (CPU or free Colab T4)** | Google Colab Free Tier GPU Tesla T4 (16GB VRAM) |
| **Estimated training time per run** | $\sim$ 8–12 menit per *run* (30 *epochs*, batch size 32, resolusi $224 \times 224$ pada $\sim$ 3.000 citra) |
| **Number of runs required** | 12 *runs*: 3 konfigurasi utama [*Scratch CNN*, *TL Aug-ON*, *TL Aug-OFF*] $\times$ 3 *random seeds* + 3 *sanity check runs* |
| **Storage for artefacts** | $\sim$ 600 MB untuk *model checkpoints* (`.pt`), *training logs*, dan visualisasi *confusion matrix* |

**RPS Policy Compliance.** Rencana ini sesuai dengan batas komputasi RPS (*Google Colab free tier*); jika waktu terbatas, pengujian *ablation* dipangkas dari 3 *seeds* menjadi 1 *fixed seed* (`seed=42`) tanpa mengurangi perbandingan model utama.

## 7. AI Use Plan

- **Assistant tools:** Google Gemini dan GitHub Copilot.
- **Permitted vs off-limits tasks:** Diizinkan untuk *debugging data loader*, kode *boilerplate plotting*, dan perapian LaTeX; dilarang menghasilkan angka metrik fiktif atau analisis kausal *error analysis* tanpa inspeksi visual citra kegagalan *test set*.
- **Verification protocol:** Seluruh skrip dijalankan deterministik melalui satu *single command* ber-*fixed seed*; setiap metrik divalidasi langsung terhadap *raw evaluation log* yang dihasilkan mesin.